

화장품 리뷰 감성분석 서비스

웹 크롤링 프로젝트 발표
고윤혁

목차

- 1 데이터 수집 과정
- 2 라벨링 문제와 해결
- 3 AI 모델 구현
- 4 모델 비교
(LSTM, GRU, Transformer)
- 5 시연

01. 데이터 수집 과정

플랫폼	건수	방식
무신사	231,029건	직접 크롤링
올리브영	222,451건	임현우 크롤링
쿠팡	78,484건	김동호 크롤링
합계	531,964건	3명 데이터 통합

총 50만 건이 넘는 리뷰를 3개 플랫폼에서 통합 수집

어려움 ① 상품 정보를 못 가져옴

React 기반 사이트라 처음 잡은 HTML 선택자가 모두 틀려 상품이 0개 검색됨
→ 해결: 페이지 구조를 다시 확인해서 수정

어려움 ② 리뷰가 일부만 보임

리뷰를 더 가져오려 했지만 같은 내용만 반복돼서 수집이 안됨
→ 해결: 처음엔 “이전 후기 보기”라는 버튼이 페이지 이동 버튼이라고 생각하고 클릭 했는데 실제로는 페이지를 아래로 스크롤해야 추가 리뷰가 로드되는 구조라 스크롤을 자동으로 내려주는 동작을 넣어 갖고 옴

02. 라벨링 문제와 해결

0.4%

무신사 평점 기준

부정 리뷰가 거의 없음
(만족도 높은 구매자만 평점)

21.9%

키워드 추측 (1차 시도)

부정 키워드로 직접 분류
→ 오탐 다수 발생

25.0%

3사 통합 + 실제 평점

올리브영.쿠팡은 부정 비율
8~17%

최종 해결 방법


- 팀원이 크롤링한 올리브영.쿠팡 데이터는 실제 평점 기준 부정 비율이 8~17%이다.
- 3개 플랫폼을 합치고 키워드 추측 대신 실제 평점(1~2점=부정, 4~5점=긍정)으로 재라벨링
- 무신사 비중이 커서 부정 비율이 낮아짐 → 긍정 리뷰 일부를 사용해서 비율을 어느정도 맞춰 부정 25% 비율 확보
- 최종 학습 데이터: 167,996건 (부정 41,999건 / 긍정 125,997건)

03. AI 모델 구현

전처리 과정

- 1 결측치 제거
- 2 정제 (한글·공백만 남기기)
- 3 중복 리뷰 제거
- 4 형태소 분석 (Okt 토큰화)

신경망 구조 (LSTM, 기준 모델)



Embedding으로 단어를 벡터로 바꿈 - LSTM(64)을 지나서 - Dense(16)
-Dense(2)로 긍정/부정을 분류.
리뷰는 문장이라 단어의 순서·맥락이 중요 → 순환신경망(LSTM) 사용
입력: 정수 인코딩 후 100단어 길이로 패딩

테스트 정확도 (LSTM)

94.2%

부정 정밀도 89.7% · 재현율 86.6%

04. 모델 비교 — LSTM · GRU · Transformer

모델	정확도	부정 F1	파라미터	학습시간	에포크
LSTM	94.2%	88.2%	130만개	269초	9
GRU	94.3%	88.5%	130만개	207초	7
Transformer	93.8%	87.3%	129만개	118초	7

- GRU는 구조가 LSTM보다 단순한데도 성능은 비슷하거나 더 좋았음 — 리뷰 문장이 짧아서 충분히 학습 가능
- Transformer는 학습 속도가 가장 빨랐지만(118초), 정확도는 셋 중 가장 낮았음
- 리뷰가 최대 100단어 정도로 짧다 보니, 긴 문맥을 잘 보는 Transformer의 장점이 크게 드러나지 않은 것으로 보임
- 이번 데이터 규모와 문장 길이에는 GRU가 가장 적합했음

모델별 Accuracy / Loss

LSTM - 94.2% / 0.169

GRU - 94.3% / 0.166

Transformer - 93.8% / 0.175

05. 시연

①

전체 통계

②

상품별 리뷰 탐색

③

실시간 감성 예측

④

모델 선택

시연 영상에서 보여줄 내용

1. 상품별 리뷰 탐색 페이지에서 리뷰와 감성 비율 확인
2. “촉촉하고 발림성도 좋아서 재구매 했어요” 입력 → 긍정
3. “피부에 트러블이 생겨서 너무 실망이에요” 입력 → 부정
4. 모델을 GRU·Transformer로 바꿔서 같은 문장 다시 예측

감사합니다

웹 크롤링 프로젝트 발표
고윤희